1 · ENTRADA

Pergunta técnica aberta do conjunto de teste (765 questões)

Sem documento
só a pergunta

Com documento
pergunta + trechos de origem

→

2 · MODELO AVALIADO

Resposta em até 20 palavras, com um único elemento técnico (causa, mecanismo, ação, termo).

Sem ferramentas nem busca externa; mesmo prompt para todos os modelos.

→

3 · JUIZ (LLM-AS-A-JUDGE)

GPT-5.4 (raciocínio médio) compara a resposta com o **gabarito** da questão.

Mesmo juiz e mesmo critério para todos os modelos e condições.

→

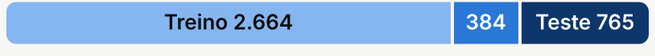
4 · VEREDITO

- Correta
- Parcial
- Incorreta

Acurácia = fração de corretas

Dataset PetroQuest v1

Questões abertas	**3.813**
Documentos técnicos	**40**
Áreas temáticas	**10**
Tipos de questão	**6**
Palavras no gabarito	**6,2**



70% 10% validação 20%

Divisão por grupo de origem (sem vazamento), estratificada por tópico, tipo e dificuldade.

Modelos avaliados (Azure OpenAI)

MODELO	FAMÍLIA	RACIOCÍNIO
GPT-4.1 Mini	GPT-4.1	não se aplica
GPT-4.1	GPT-4.1	não se aplica
GPT-5 mini	GPT-5	esforço baixo
GPT-5	GPT-5	esforço baixo
GPT-5.4*	GPT-5.4	esforço baixo

*Gerou e auditou as questões: reportado só como referência e excluído dos estratos de dificuldade.

Métricas

- **Acurácia** pelo juiz, sem e com documento, e o **ganho** com o documento
- **IC 95%** por bootstrap (2.000 reamostragens)
- **F1 de tokens** e **ROUGE-L** contra o gabarito (complementares)
- **Dificuldade empírica**: acerto dos 4 modelos independentes sem documento